Kapitel 3: Datenstrukturen und Funktionen in Python

McKinney, W. (2017). *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython.* 2. Auflage. Sebastopol, CA [u. a.]: O'Reilly.

Überarbeitet: armin.baenziger@zhaw.ch, 2. Januar 2020

- Bevor wir Add-On-Bibliotheken für die Datenmanipulation besprechen (insb. NumPy und Pandas), werden Funktionalitäten behandelt, die in der Python-Sprache fest implementiert sind und im Kurs regelmässig verwendet werden.
- Wir beginnen mit Pythons zentralen Datenstrukturen: Tupel, Listen, Dicts und Sets.
- Danach werden wir eigene Funktionen schreiben, um den Funktionsumfang von Python zu erweiteren.
- Den Abschnitt "3.3 Files and the Operating System" werden wir nicht besprechen, da wir im Kurs lediglich Pandas-Funktionen für das Lesen und Schreiben von Datendateien verwenden!
- Einiges, was in diesem Kapitel thematisiert wird, haben wir bereits im 2. Kapitel kurz besprochen.
- Das Kapitel ist somit eine (hoffentlich gute) Mischung aus Repetition und Erweiterung des Stoffs!

```
In [1]: %autosave 0

Autosave disabled
```

Datenstrukturen und Sequenzen

Pythons Datenstrukturen sind einfach, aber leistungsstark. Ihre Verwendung zu meistern ist wichtig.

Tupel (tuple)

Tupel sind nicht modifizierbare (immutable) Sequenzen von Python-Objekten mit fester Länge.

```
In [2]: tup = (4, 5, 6)
tup

Out[2]: (4, 5, 6)

In [3]: # es geht auch ohne Klammern:
    tup = 4, 5, 6
tup

Out[3]: (4, 5, 6)

In [4]: # Ein Tupel kann weitere Tupel (oder andere Sequenzen) enthalten:
    nested_tup = (4, 5, (5.1, 5.2), 6)
    nested_tup
Out[4]: (4, 5, (5.1, 5.2), 6)
```

Mit der Funktion tuple können Sequenzen/Iteratoren in Tupel konvertiert werden.

```
In [5]: liste = [4, 0, 2]
    tuple(liste)

Out[5]: (4, 0, 2)

In [6]: tuple(range(5))
Out[6]: (0, 1, 2, 3, 4)
```

```
In [7]: tup = tuple('abcd')
tup
Out[7]: ('a', 'b', 'c', 'd')
```

Auf Elemente kann mit eckigen Klammern [] zugegriffen werden. Wie in vielen anderen Programmiersprachen (z. B. C, C++, Java) hat das erste Element in einer Sequenz den Index 0. (Beispielsweise in *Matlab* oder *R* hat das erste Element hingegen den Index 1.)

```
In [8]: tup[0]
Out[8]: 'a'
```

Tupel sind nicht modifizierbar.

Tupel können mit + verknüpft (engl. concatenate) werden.

```
In [10]: (1, 2, 'drei') + ('vier', 'fünf')
Out[10]: (1, 2, 'drei', 'vier', 'fünf')
```

Multiplikation eines Tupel mit einer ganzen Zahl führt - wie bei Listen oder Zeichenketten auch - dazu, dass das Tupel vervielfacht wird.

```
In [11]: (1, 2) * 3
Out[11]: (1, 2, 1, 2, 1, 2)
```

Tupel entpacken (unpacking tuples)

```
In [12]: tup = (4, 5, 6)
a, b, c = tup # a ist nun gleich 4, b=5, c=6
a * b * c
Out[12]: 120
```

Diese Funktionalität erlaubt es auch, Variablennamen sehr einfach zu tauschen. In anderen Sprachen würde man typischerweise wie folgt vorgehen:

```
In [13]: a, b = 1, 2
# a und b sollen nun getauscht werden:
tmp = a
a = b
b = tmp
print('a ist nun', a, 'und b ist nun', b)
a ist nun 2 und b ist nun 1
```

In Python kann man das einfacher coden:

```
In [14]: a, b = b, a # wieder zurück getauscht
print('a ist nun', a, 'und b ist nun', b)
a ist nun 1 und b ist nun 2
```

Häufig wird das Entpacken in Iterationen über Sequenzen von Tupeln oder Listen gebraucht.

```
In [15]: seq = [(6, 7), (1, 5), (3, 1)] # Liste mit drei Tupel
    for a, b in seq:
        print(b-a)

1
4
-2
```

Tupel-Methoden

Da Tupel nicht modifizierbar sind, gibt es nur wenige Methoden auf Tupel. Sehr nützlich ist aber count (auch auf Listen anwendbar), welche zählt, wie oft ein bestimmter Wert in einem Tupel vorkommt.

```
In [16]: a = (1, 2, 2, 3, 2)
a.count(2)
Out[16]: 3
```

Kontrollfragen:

```
In [17]: # Gegeben:
         tup1 = ('Altdorf', 'Baden', 'Winterthur')
         tup2 = ('a', ('b', 'c'), 'd')
         print('tup1:', tup1)
         print('tup2:', tup2)
         tup1: ('Altdorf', 'Baden', 'Winterthur')
         tup2: ('a', ('b', 'c'), 'd')
In [18]: # Frage 1: Was ist der Output?
         tup1[1]
Out[18]: 'Baden'
In [19]: # Frage 2: Was ist der Output?
         tup2[1]
Out[19]: ('b', 'c')
In [20]: # Frage 3: Was könnte wohl nun der Output sein?
         tup2[1][0]
Out[20]: 'b'
In [21]: # Frage 3: Was könnte wohl nun der Output sein?
         tup1[2][0]
Out[21]: 'W'
```

Listen (list)

Listen sind im Gegensatz zu Tupel modifizierbare (mutable) Sequenzen von Python-Objekten mit variabler Länge.

• Erzeugung einer Liste mit eckiger Klammer:

```
In [22]: list_1 = [2, 3, 7, 6]
list_1
Out[22]: [2, 3, 7, 6]
```

• Erzeugung einer Liste aus einem anderen Objekt mit der Funktion list:

```
In [23]: tupel = ('eins', 2, 'drei')
    list_2 = list(tupel)
    list_2.
Out[23]: ['eins', 2, 'drei']

In [24]: list_2[1] = 'zwei'  # Listen sind modifizierbar.
    list_2.
Out[24]: ['eins', 'zwei', 'drei']

In [25]: iterator = range(10)
    iterator
        # nur ein "Platzhalter" für die ganzen Zahlen von 0 bis (aber ohne) 10

Out[25]: range(0, 10)

In [26]: list(iterator)  # Nun haben wir eine Liste.
Out[26]: [0, 1, 2, 3, 4, 5, 6, 7, 8, 9]
```

Elemente hinzufügen und entfernen

• Element können mit der Methode append am Ende der Liste hinzugefügt werden:

```
In [27]: list_2.append('vier')
list_2
Out[27]: ['eins', 'zwei', 'drei', 'vier']
```

Mit pop können wir Elemente aus Listen entfernen. Per Default wird das letzte Element gelöscht.

```
In [28]: list_2.pop()
list_2
Out[28]: ['eins', 'zwei', 'drei']
```

Mit in kann überprüft werden, ob ein Wert in einer Liste vorkommt.

```
In [29]: 'fünf' in list_2
Out[29]: False
In [30]: 'fünf' not in list_2
Out[30]: True
```

Mit + können zwei Listen verkettet werden.

```
In [31]: a = [0, 1]
b = [2, 3, 4]
c = a + b
c
Out[31]: [0, 1, 2, 3, 4]
```

Sortieren

Listen können mit der sort -Methode "in-place" (ohne ein neues Objekt zu kreieren) sortiert werden.

Man kann sort einige Argumente übergeben. Beispiele:

• Absteigende Sortierung:

```
In [33]: a.sort(reverse=True)
a
Out[33]: [7, 5, 2, 1]
```

Slicing

Aus den meisten Sequenz-Typen kann man Ausschnitte durch die "Slice-Notation" auswählen. Die grundsätzliche Form lautet Sequenz [start:stop] , wobei das Element an der Stelle stop nicht mehr zählt.

```
In [34]: seq = [7, 1, 0, 6, -1, 3]
seq[1:4]
Out[34]: [1, 0, 6]
```

Man kann Slices auch zuweisen:

```
In [35]: seq[1:2] = [99, 999] # Ein Wert wird durch zwei Werte ersetzt!
seq # Man beachte: Die Liste enthält nun ein Element mehr.
Out[35]: [7, 99, 999, 0, 6, -1, 3]
```

Dies ist nicht identisch mit folgender Syntax, welche eine verschachtelte Liste erstellt:

```
In [36]: seq[1] = [9999, 99999]
seq
Out[36]: [7, [9999, 99999], 999, 0, 6, -1, 3]
```

Man kann start oder stop weglassen, womit dann entweder der Anfang oder das Ende der Sequenz verwendet werden.

```
In [37]: seq = list('abcdefgh')
seq
Out[37]: ['a', 'b', 'c', 'd', 'e', 'f', 'g', 'h']
In [38]: seq[:3]
Out[38]: ['a', 'b', 'c']
In [39]: seq[3:]
Out[39]: ['d', 'e', 'f', 'g', 'h']
```

Negative Indizes slicen die Sequenz vom Ende her.

```
In [40]: seq[-2:]
Out[40]: ['g', 'h']
In [41]: seq[-3:-1]
Out[41]: ['f', 'g']
```

Nach einem zweiten Doppelpunkt kann ein step eingegeben werden, z. B. um jedes zweite Element zu nehmen.

```
In [42]: seq[1:6:2]
Out[42]: ['b', 'd', 'f']
In [43]: seq[::2]
Out[43]: ['a', 'c', 'e', 'g']
```

Mit folgendem Trick kann man die Reihenfolge einer Liste oder eines Tupels umdrehen:

```
In [44]: seq[::-1]
Out[44]: ['h', 'g', 'f', 'e', 'd', 'c', 'b', 'a']
```

Kontrollfragen:

```
In [45]: # Gegeben:
         liste = list('ABCDE')
Out[45]: ['A', 'B', 'C', 'D', 'E']
In [46]: | # Frage 1: Was ist der Output?
         liste[-1]
Out[46]: 'E'
In [47]: # Frage 2: Was ist der Output?
         liste[1:3]
Out[47]: ['B', 'C']
In [48]: | # Frage 3: Wie kann der String 'F' der Liste hinzugefügt werden?
         liste.append('F')
         liste
Out[48]: ['A', 'B', 'C', 'D', 'E', 'F']
In [49]: # Alternative Lösung:
         liste.pop() # zuerst letzten Wert ('F') wieder löschen.
         liste = liste + ['F'] # Alternative Lösung
Out[49]: ['A', 'B', 'C', 'D', 'E', 'F']
In [50]: # Frage 4: Ersetzen Sie in "liste" den ersten Buchstaben durch "a":
         liste[0] = 'a'
         liste
Out[50]: ['a', 'B', 'C', 'D', 'E', 'F']
In [51]: # Frage 5: Was ist der Output?
         liste[:2] = ['x', 'y']
         liste
Out[51]: ['x', 'y', 'C', 'D', 'E', 'F']
```

Zwei Sequenz-Funktionen in Python

sorted

Die sorted -Funktion gibt eine neue sortierte Liste aus den Elementen einer beliebigen Sequenz zurück:

```
In [52]: sorted([7, 1, 2, 6, 0, 3, 2])
Out[52]: [0, 1, 2, 2, 3, 6, 7]
In [53]: sorted('Thomas Muster')
Out[53]: [' ', 'M', 'T', 'a', 'e', 'h', 'm', 'o', 'r', 's', 's', 't', 'u']
```

- Die sorted -Funktion akzeptiert dieselben Argumente wie die sort -Methode auf Listen.
- Die sort -Methode ist im Gegensatz zur sorted -Funktion "in-place" (Objekt wird permanent verändert):

Kontrollfragen:

```
In [56]: # Gegeben:
    liste = [5, 6, -4]

Out[56]: [5, 6, -4]

In [57]: # Frage 1: Was ist der Output?
    sorted(liste)

Out[57]: [-4, 5, 6]

In [58]: # Frage 2: Was ist der Output?
    liste

Out[58]: [5, 6, -4]

In [59]: # Frage 3: Was ist der Output?
    liste.sort()
    liste
Out[59]: [-4, 5, 6]
```

reversed

- reversed iteriert über die Elemente einer Sequenz in umgekehrter Reihenfolge.
- reversed ist ein *Iterator*, so dass er nicht die umgekehrte Sequenz erzeugt, bis er materialisiert wird (z. B. mit list oder einer for -Schleife).

```
In [60]: a = [2, 5, 1, 3]
    reversed(a)  # Iterator ist angelegt.

Out[60]: <list_reverseiterator at 0x137b69d9b70>

In [61]: list(reversed(a))  # Mit tuple() gäbe es ein Tupel.

Out[61]: [3, 1, 5, 2]
```

dict

- dict ist eine weitere wichtige Datenstruktur in Python.
- Es handelt sich um eine flexible Kollektion von Schlüssel-Werte-Paaren.
- dict -Objekte können mit geschweiften Klammern {} und Doppelpunkten, welche Schlüssel und Werte trennen, erstellt werden.

```
In [62]: dict1 = {'a' : 'Anna', 'b' : 'Benno'}
          dict1
Out[62]: {'a': 'Anna', 'b': 'Benno'}
In [63]: dict1['a'] # Wert mit Schlüssel a auslesen.
Out[63]: 'Anna'
In [64]: | # Werte (values) dürfen auch Listen (oder andere Sequenzen) sein:
          dict1
          dict1['c'] = ['Claude', 'Claudia']
          dict1
Out[64]: {'a': 'Anna', 'b': 'Benno', 'c': ['Claude', 'Claudia']}
In [65]: dict1['c']
Out[65]: ['Claude', 'Claudia']
In [66]: dict1['c'][0]
Out[66]: 'Claude'
In [67]: 'b' in dict1
                        # Prüft, ob der Schlüssel b in d1 enthalten ist.
Out[67]: True
Löschen mit del oder pop:
In [68]: dict2 = dict1.copy() # Kopie von dict1 erstellen.
In [69]: del dict2['b']
         dict2
Out[69]: {'a': 'Anna', 'c': ['Claude', 'Claudia']}
```

Schlüssel und Werte können mit den Methoden keys und values ausgelesen werden.

```
In [70]: dict1.keys()  # Typ "dict_keys"
Out[70]: dict_keys(['a', 'b', 'c'])
In [71]: list(dict1.keys())  # Keys als Liste
Out[71]: ['a', 'b', 'c']
```

```
In [72]: dict1.values() # Typ "dict_values"
Out[72]: dict_values(['Anna', 'Benno', ['Claude', 'Claudia']])
In [73]: list(dict1.values()) # Werte als Liste
Out[73]: ['Anna', 'Benno', ['Claude', 'Claudia']]
```

Kontrollfragen:

```
In [74]: # Gegeben:
    Loehne = {'K1': 4500, 'K2': 5750, 'K3': 7000}
Loehne
Out[74]: {'K1': 4500, 'K2': 5750, 'K3': 7000}
In [75]: # Frage 1: Was ist der Output?
    Loehne['K2']
Out[75]: 5750
In [76]: # Frage 2: Was ist der Output?
    list(Loehne.values())
Out[76]: [4500, 5750, 7000]
```

set

- Ein set (Menge) ist eine ungeordnete Kollektion von unterschiedlichen Elementen.
- Zwei Möglichkeiten, wie ein set erstellt werden kann:

```
In [77]:  # Möglichkeit 1:
    {2, 2, 2, 1, 3, 3}  # Es gibt nur drei unterschiedliche Elemente!

Out[77]:    {1, 2, 3}

In [78]:  # Möglichkeit 2:
    tup = (2, 2, 2, 1, 3, 3)  # Liste ginge auch!
    set(tup)

Out[78]:    {1, 2, 3}
```

Mit set () lassen sich beispielsweise alle unterschiedlichen Elemente in einer Sequenz auflisten:

```
In [79]: waschmittel = ['Omo', 'Ariel', 'Omo', 'Dash', 'Ariel']
set(waschmittel)
Out[79]: {'Ariel', 'Dash', 'Omo'}
```

Oder es lässt sich die Anzahl unterschiedlicher Elemente ermitteln:

```
In [80]: len(set(waschmittel))
Out[80]: 3
```

List-Comprehensions

- **List-Comprehension** ist ein geschätztes Feature von Python, mit dem eine neue Liste dadurch erstellt wird, dass man die Elemente einer bestehenden Kollektion durch einen Filter auswählt.
- List-Comprehension erlaubt das mit einem Ausdruck der Form:

```
[expr for val in collection if condition]
```

- Die Filter-Bedingung kann auch weggelasen werden.
- Beispiel 1: Konvertierung der Strings in einer Liste in Grossbuchstaben

```
In [81]: Strings = ['Ein', 'kleiner', 'Versuch', 'in', 'Python', '.']
```

Vorbemerkung: Mit der Methode upper() wird ein String in Grossbuchstaben umgewandelt:

```
In [82]: Strings[4].upper()
Out[82]: 'PYTHON'
In [83]: # Ganze Liste in Grossbuchstaben umwandeln
# Lösung mit for-Loop:
Resultat = [] # Leere Liste initialisieren

for string in Strings:
    Resultat.append(string.upper())
Resultat
Out[83]: ['EIN', 'KLEINER', 'VERSUCH', 'IN', 'PYTHON', '.']
In [84]: # Lösung mit List-Comprehension:
[string.upper() for string in Strings]
Out[84]: ['EIN', 'KLEINER', 'VERSUCH', 'IN', 'PYTHON', '.']
```

• Beispiel 2: Auswahl von Strings mit Mindestlänge 3 und gleichzeitige Konvertierung in Grossbuchstaben

```
In [85]: [string.upper() for string in Strings if len(string) >= 3]
Out[85]: ['EIN', 'KLEINER', 'VERSUCH', 'PYTHON']
```

Kontrollfragen:

```
In [86]: # Gegeben:
    Orte = ['Basel', 'Winterthur', 'Zug', 'Zürich']
Out[86]: ['Basel', 'Winterthur', 'Zug', 'Zürich']
In [87]: # Frage 1: Was ist der Output?
    [len(ort) for ort in Orte]
Out[87]: [5, 10, 3, 6]
In [88]: # Frage 2: Was ist der Output?
    [len(ort) for ort in Orte if ort[0]=='Z']
Out[88]: [3, 6]
```

```
In [89]: # Frage 3: Erstellen Sie aus "Orte" eine Liste, welche je die ersten
# Buchstaben der Ortschaften enthält. Verwenden Sie hierzu eine List-
# Comprehension.
[ort[0] for ort in Orte]
Out[89]: ['B', 'W', 'Z', 'Z']
```

Es gibt auch Set- und Dict-Comprehensions, auf die wir aber nicht näher eingehen.

Funktionen

Funktionen sind die primäre und wichtigste Methode, um Code in Python zu organsieren und wiederzuverwenden.

- Falls gleicher oder ähnlicher Code mehr als einmal gebraucht wird, kann es lohnenswert sein, eine (wiederverwendbare) Funktion zu schreiben.
- Funktionen machen den Code lesbarer, weil dadurch einer Gruppe von Python-Befehlen einen Namen gegeben wird.
- Funktionen werden mit dem Schlüsselwort def eingeleitet.

```
In [90]: def celsius(fahrenheit):
    return (fahrenheit-32)*5/9

In [91]: celsius(100)
Out[91]: 37.77777777778
```

Eine Funktion kann auch mehrere Argumente haben:

```
In [92]: def Summe(x, y):
    return x+y
Summe(2,5)
Out[92]: 7
```

Man kann einer Funktion auch Default-Werte übergeben:

```
In [93]: def eine_Funktion(x, y, z=1): # z=1, falls z nicht übergeben wird.
    return (x + y) * z

In [94]: eine_Funktion(2, 3, 4)  # Argumentübergabe durch Position

Out[94]: 20

In [95]: eine_Funktion(4, 3, 2)  # Argumentübergabe durch Position

Out[95]: 14

In [96]: eine_Funktion(z=4, y=3, x=2)  # Argumentübergabe durch Namen  # So ist die Reihenfolge irrelevant.

Out[96]: 20

In [97]: eine_Funktion(2, 3)  # Jetzt gilt der Default z=1

Out[97]: 5
```

Man kann Funktionen auch verschachteln:

```
In [98]: Summe(Summe(1,2), Summe(3,4))
Out[98]: 10
```

```
In [99]: Summe(celsius(100), celsius(90))
Out[99]: 70.0
```

Hinweis: Schlüsselwort-Argumente (hier z = 1) müssen Positions-Argumente (hier x, y) folgen, also am Ende stehen.

Kontrollfragen:

Mehrere Funktionswerte zurückgeben

In Python können sehr einfach mehrere Werte durch eine Funktion zurückgegeben werden.

```
In [102]: def nonsense():
    a = 5
    b = 6
    c = '7'
    return a, b, c

    x, y, z = nonsense()
    x + y + int(z)
Out[102]: 18
```

Eigentlich wird lediglich ein Tupel durch die Funktion zurückgegeben, welches dann entpackt wird. Hier die Verdeutlichung:

```
In [103]: nonsense()
Out[103]: (5, 6, '7')
```

Es ist auch möglich ein dict zurückzugeben:

```
In [104]: def add_mult(x1, x2):
    return { 'Summe': (x1 + x2), 'Produkt': (x1*x2) }

In [105]: add_mult(2, 3)

Out[105]: {'Summe': 5, 'Produkt': 6}
```

Funktionen sind Objekte

Da Python-Funktionen Objekte sind, können viele Konstrukte leicht ausgedrückt werden, die in anderen Sprachen schwierig sind:

Dateien und Betriebssystem

Wir werden im Kurs lediglich Pandas-Funktionen für das Lesen und Schreiben von Datendateien verwenden und besprechen diesen Abschnitt im Lehrmittel somit nicht.

Fazit

- Sie sind nun mit einigen wichtigen Grundlagen der Python-Sprache vertraut.
- Im nächsten Kapitel werden wir die Bibliothek NumPy kennenlernen.
- Wir werden sehen, dass man in NumPy mathematische Funktionen auf ganze Arrays anwenden kann, ohne Schleifen schreiben zu müssen.